

1. 문제 정의 (Problem Statement)

최근 공공 민원(2023년 약 1,900만 건)이 급증하고 있으나, 관련 데이터가 기관별로 분산되어 있고 비정형 텍스트로 존재한다. 이로 인해 사회 불만의 구조적 원인과 주제 간 연관성을 파악할 정량적 지표가 부재한 상황이다.

본 연구는 2018년부터 2024년까지의 국민신문고 및 지자체 민원 데이터를 통합하고, 자연어 처리를 통해 시공간적 패턴과 주제 간 상관 구조를 분석하여 공공자원 배분 및 정책 우선순위 결정을 위한 데이터 기반 의사결정 근거를 마련하는 것을 목표로 한다.

2. 데이터 설명 (Data Description)

- 수집 대상: 2018년 ~ 2024년 공공 민원 및 청원 데이터
- 수집 출처:
 - 국민신문고 (API 활용 - 현재 화재로 점검 중, 복구 후 시도)
 - 청와대 청원 아카이브 (Python Requests/BeautifulSoup 스크레이퍼)
 - 6대 광역시 민원 게시판 (Python 스크레이퍼 및 Octoparse 병행)
- 핵심 필드: id, date (날짜), title (제목), content (본문), region_code (행정구역), views (조회수), source_category (원본 분류)
- 데이터베이스: MongoDB (NoSQL) 채택. JSON(BSON) 형태의 유연한 스키마로 다중 소스에서 수집된 비정형 데이터를 효율적으로 저장 및 관리.

3. 연구 방법론 (Planned Methodology)

1. 데이터 정제: MongoDB 적재. Regex로 HTML 태그, URL 등 노이즈 제거. 정규표현식으로 PII 비식별화.

2. 주제 분류 (Hybrid): Mecab-ko (토큰화) 및 kss (문장 분리) 전처리. BERTopic (비지도)로 8대 상위 카테고리 확정. KoBERT (지도) 파인튜닝 및 Active Learning으로 다중 레이블 분류 모델 고도화.

3. 시공간 분석: 주제별/월별 증감률($(t_n - t_{n-1}) / t_{n-1}$) 시계열 분석. '인구 10만 명당 민원 건수'로 정규화, Geopandas/Folium 핫스팟 히트맵 시각화.

4. 네트워크 분석: 8개 주제(노드) 간 동시발생(Co-occurrence) 행렬로 엣지 가중치 부여. NetworkX로 중심성(Centrality) 및 Louvain 알고리즘 커뮤니티(Community) 탐지.

5. 대시보드 구축: 핵심 지표(KPI) 정의. Plotly (Dash) 또는 Streamlit으로 3-Way 연동 시각화(지도 ↔ 시계열 ↔ 네트워크) 인터랙티브 대시보드 구축.