

1. 문제 정의 (Problem Statement)

최근 한국 사회에서는 경기 침체, 주거 불안, 환경 문제, 지역 불균형 등 복합적인 요인으로 인해 공공 불만이 꾸준히 증가하고 있다. 행정안전부 「국민신문고 통계연보(2024)」에 따르면, 2023년 국민신문고를 통한 전체 민원 접수 건수는 약 1,900만 건 이상으로, 5년 전 대비 큰 폭으로 증가하였다. 이러한 민원은 교통, 주거, 환경, 복지 등 국민 생활 전반의 문제를 포괄하며, 특히 생활 불편 및 행정서비스 개선 요구가 지속적으로 확대되는 추세를 보인다. 그러나 이러한 공공 민원 데이터는 기관별로 분리되어 관리되고, 자유서술형의 비정형 텍스트 형태로 존재하기 때문에 전국 단위의 통합 분석이 어렵다. 그 결과 사회 불만의 구조적 원인과 주제 간 연관성을 정량적으로 파악하기 위한 지표가 부재한 상황이다.

본 프로젝트는 2018년부터 2024년까지의 국민신문고 및 지방자치단체 민원 데이터를 통합하여 사회 불만의 시공간적 패턴과 주제 간 상관 구조를 분석하고, 이를 통해 공공자원 배분과 정책 우선순위 결정에 활용할 수 있는 데이터 기반 의사결정 근거를 마련하는 것을 목표로 한다.

2. 데이터 설명 (Data Description)

2.1. 데이터 수집 계획 및 출처

- 국민신문고 - API 활용 (예정)
 - 화재 사건 으로 인해 아직 확인 불가. 복구 후 재확인 필요
- 시청별 민원 게시판 - Web Scraper
- 청와대 청원 아카이브 - Web Scraper
- Web scraper 사용 불가 시청 민원게시판 (ex. 서울특별시청) - Octoparse 사용

2.2. 데이터 구조 및 필드 정의

수집된 비정형 데이터는 JSON 기반의 구조화된 형태로 변환하여 저장할 계획

- 날짜 - String/Date (민원 또는 청원 게시물이 작성된 날짜.)
- 조회수 - Integer (해당 게시물의 조회수)
- 제목 - String (민원 또는 청원 게시물의 제목)
- 민원내용 -String (민원 또는 청원 게시물의 본문 내용 (비정형 텍스트 데이터).)
- 행정구역 - String (민원 또는 청원 게시물의 출처)

2.3. 데이터베이스 구축

수집 및 정제된 JSON 기반의 데이터를 저장하기 위해 JSON 기반 NoSQL 데이터베이스를 활용하여 시스템을 구축한다.

- 선택 데이터베이스: MongoDB (JSON 형태의 BSON 문서를 효율적으로 저장 및 관리).

3. 연구 방법론 (Planned Methodology)

3.1 데이터 수집 및 정제 파이프라인 구축

- 데이터 수집 (Data Collection):** 본 연구는 2018년부터 2024년까지의 공공 민원 텍스트를 수집 대상으로 하며, 데이터의 포괄성 확보를 위해 다중 소스(multi-source) 접근 방식을 채택한다.
- 데이터 정제 (Data Cleansing):** 수집된 데이터는 HTML 태그, 이모지, URL 등 분석에 불필요한 노이즈를 정규표현식 (Regex)을 통해 일괄 제거한다. 또한 "감사합니다" 등 내용과 무관하거나 30자 이하의 유의미한 정보가 없는 단문 민원은 필터링하여 데이터 품질을 확보한다.
- 비식별화 (De-identification):** 민원인의 개인정보보호를 위해, 정규표현식을 사용하여 이름(예: 김○○), 연락처, 상세 주

소, 계좌번호 등 식별 가능한 개인정보(PII)를 탐지하고 [MASK] 토큰 등으로 일괄 대체한다.

4. **데이터베이스 스키마 표준화:** 상이한 출처(API, 크롤링)에서 수집된 데이터를 통일된 스키마로 매핑하여 MongoDB에 적재한다.

3.2 하이브리드 접근 방식의 텍스트 전처리 및 주제 분류

민원 텍스트를 정량 분석 단위로 변환하기 위해, NLP 전처리와 함께 지도/비지도 학습을 결합한 주제 분류 모델을 구축한다.

1. **NLP 전처리 (NLP Preprocessing):** 형태소 분석, 정규화 및 불용어 제거, 분석 단위 확정
2. **주제 분류 (Topic Classification):**
 - **1단계 (비지도 토픽 추출):** 먼저, 전체 민원 데이터셋에 BERTopic 모델을 적용하여 비지도 학습 기반의 잠재 토픽을 자동 추출한다. 이 결과를 바탕으로 민원의 주요 키워드 군집을 파악하여, 연구의 최종 분류 체계인 8대 상위 카테고리(교통, 환경, 주거 등)를 확정하는 근거로 활용한다.
 - **2단계 (지도 학습 기반 분류):** 8대 카테고리가 확정되면, 이는 "다중 레이블 분류(Multi-label Classification)" 문제로 정의된다. 한국어 사전학습 모델인 KoBERT를 기반으로 파인튜닝(fine-tuning)을 진행한다.
 - **액티브 러닝(Active Learning) 적용:** 3~5만 건에 달하는 전체 데이터셋을 수동으로 라벨링하는 것은 비효율적이므로, 소수 라벨링(2,000건)으로 최대 효율을 내는 액티브 러닝을 도입한다.

3.3 시공간적 불만 트렌드 분석 (Spatio-temporal Analysis)

분류된 민원 데이터를 시계열 및 지리 정보와 결합하여 사회 불만의 시공간적 패턴을 분석한다.

1. **시계열 분석 (Time-series Analysis):** 분류된 8개 주제별 민원 건수를 월별, 연도별로 집계한다. 단순 건수 변화와 함께, 전년 동기 대비 증감률 지표($\frac{t_n - t_{n-1}}{t_{n-1}}$)를 계산, 계절성 요인이나 특정 정책 이벤트 전후의 변화를 포착한다.
2. **공간 분석 (Spatial Analysis):** 민원 발생 행정구역(region_code)을 기준으로 주제별 민원 발생 건수를 집계한다. 지역 간 공정한 비교를 위해, '인구 10만 명당 민원 발생 건수'로 정규화한다. 이 정규화된 지표를 지역별 히트맵으로 시각화하며, 이를 통해 정책적 개입이 시급한 지역을 식별한다.

3.4 주제 간 상관 네트워크 분석 (Topic Network Analysis)

사회 불만은 단일 주제로 발생하기보다 복수의 주제가 얹혀 발생하는 경우가 많으므로 네트워크 분석을 도입한다.

1. **네트워크 정의:** 8개의 대주제를 노드(Node)로 정의한다.
2. **관계(Edge) 가중치 계산:** 단일 민원 문서내에서 2개 이상의 주제가 동시에 등장할 경우, 해당 주제 노드 간의 엣지(Edge)에 +1의 가중치를 부여한다. 이 과정을 모든 민원에 대해 반복하여 Co-occurrence Matrix을 생성한다.
3. **네트워크 분석:** NetworkX 라이브러리를 사용하여 가중치가 부여된 네트워크 그래프를 구축하고, 주요 네트워크 지표를 분석한다.

3.5 지표 설계 및 인터랙티브 대시보드 구축

모든 분석 결과를 통합하여, 정책 담당자가 직관적으로 트렌드를 파악하고 의사결정에 활용할 수 있는 인터랙티브 대시보드를 구축한다.

1. **핵심 지표 설계:** '주제별 민원 비중', '전년 대비 증가율', '지역별 정규화된 불만 지수', '주제 간 연결 강도' 등 핵심 지표(KPI)를 최종 정의한다.
2. **대시보드 구축:** Plotly (Dash) 또는 Streamlit을 사용하여 웹 기반 인터랙티브 대시보드를 개발한다.
3. **기대 기능:**
 - **시공간 필터링:** 사용자가 연도, 월, 특정 광역시를 선택하여 해당 조건의 데이터만 동적으로 조회할 수 있다.
 - **연동 시각화:** (a) 지도에서 특정 지역을 클릭하면, (b) 해당 지역의 시간별 민원 트렌드와 (c) 주제별 네트워크 구조가 연동되어 나타나는 3-Way 시각화를 구현한다.
 - **결과물:** 최종적으로 '사회 불만 트렌드맵'과 '문제 상관 네트워크 대시보드'를 완성하여 정책 우선순위 설정의 근거 자료로 제공한다.