

3. 연구 방법론 (Planned Methodology)

본 연구는 공공 민원 텍스트에 내재된 사회 불만 트렌드를 정량적으로 도출하기 위해, 데이터 수집, 자연어 처리(NLP), 시공간 통계 분석, 그리고 네트워크 과학을 결합한 통합적 방법론을 채택한다. 전체 파이프라인은 5단계로 구성되며, 각 단계는 유기적으로 연결되어 원시 데이터(raw data)를 정책 결정에 활용 가능한 실행 가능한 지표(actionable indicator)로 변환하는 것을 목표로 한다.

3.1 데이터 수집 및 정제 파이프라인 구축

연구의 신뢰도는 데이터의 품질과 범위에 직결되므로, 체계적인 데이터 수집 및 정제 파이프라인을 우선 구축한다.

- 데이터 수집 (Data Collection):** 국민신문고 API를 통해(data description에 따라 바뀜) 2018년부터 2024년까지의 공개 민원 데이터를 수집하며, API 접근이 제한적인 6대 광역시(서울, 부산, 인천, 대구, 대전, 광주)의 '새울전자민원창구' 등 지방자치단체 게시판은 Python의 Requests 및 BeautifulSoup 라이브러리를 활용한 웹 크롤러(data description에 따라 바뀜)를 개별 설계하여 데이터를 확보한다.
- 데이터 정제 (Data Cleansing):** 수집된 데이터는 HTML 태그, 이모지, URL 등 분석에 불필요한 노이즈를 정규표현식(Regex)을 통해 일괄 제거한다. 또한 "감사합니다" 등 내용과 무관하거나 30자 이하의 유의미한 정보가 없는 단문 민원은 필터링하여 데이터 품질을 확보한다.
- 비식별화 (De-identification):** 민원인의 개인정보보호를 위해, 정규표현식을 사용하여 이름(예: 김○○), 연락처, 상세 주소, 계좌번호 등 식별 가능한 개인정보(PII)를 탐지하고 [MASK] 토큰 등으로 일괄 대체한다.
- 데이터베이스 스키마 표준화:** 상이한 출처(API, 크롤링)에서 수집된 데이터를 (id, title, content, date, region_code, category, status, url, source)의 통일된 스키마로 매핑하여 관계형 데이터베이스에 적재한다.

3.2 하이브리드 접근 방식의 텍스트 전처리 및 주제 분류

비정형 민원 텍스트를 정량 분석 단위로 변환하기 위해, NLP 전처리와 함께 지도/비지도 학습

을 결합한 하이브리드 주제 분류 모델을 구축한다.

1. NLP 전처리 (NLP Preprocessing):

- **형태소 분석:** 한국어 처리에 높은 성능과 속도를 보이는 Mecab-ko 형태소 분석기를 사용하여 민원 본문을 토큰화한다.
- **정규화 및 불용어 제거:** 표제어 추출(lemmatization)을 통해 '불편함', '불편하다' 등을 '불편'으로 통일한다. 또한, '민원', '요청', '바랍니다'와 같이 모든 민원에 공통으로 등장하지만 주제 분류에 기여하지 못하는 단어들을 선별하여 자체 불용어 사전(custom stopwords list)을 구축하고 이를 제거한다.
- **분석 단위 확정:** 민원 본문 전체가 아닌, "부정", "요구", "제안"의 의미를 담고 있는 문장(sentence)을 핵심 분석 단위로 설정한다. kss (Korean Sentence Splitter) 라이브러리를 활용해 문장을 분리하고, 긍정/중립 문장은 필터링하여 핵심 불만 사항에 집중한다

2. 주제 분류 (Topic Classification):

- **1단계 (비지도 토픽 추출):** 먼저, 전체 민원 데이터셋에 BERTopic 모델을 적용하여 비지도 학습 기반의 잠재 토픽을 자동 추출한다. BERTopic은 BERT 임베딩을 통해 문맥을 이해하고 c-TF-IDF를 활용해 응집력 높은 토픽을 도출하므로, LDA보다 일관성 있는 주제 군집을 식별할 수 있다. 이 결과를 바탕으로 민원의 주요 키워드 군집을 파악하여, 연구의 최종 분류 체계인 8대 상위 카테고리(교통, 환경, 주거 등)를 확정하는 근거로 활용한다.
- **2단계 (지도 학습 기반 분류):** 8대 카테고리가 확정되면, 이는 "다중 레이블 분류(Multi-label Classification)" 문제로 정의된다. 한국어 사전학습 모델인 KoBERT를 기반으로 파인튜닝(fine-tuning)을 진행한다.
- **액티브 러닝(Active Learning) 적용:** 3~5만 건에 달하는 전체 데이터셋을 수동으로 라벨링하는 것은 비효율적이므로, 소수 라벨링(2,000건)으로 최대 효율을 내는 액티브 러닝을 도입한다.
 - i. 초기 2,000건의 데이터를 수동 라벨링하여 1차 KoBERT 모델을 학습시킨다.
 - ii. 이 모델을 사용하여 나머지 미분류 데이터의 예측 확률을 계산한다.
 - iii. 모델이 가장 혼동하는(uncertain) 샘플(예: 예측 확률이 0.5에 근접한 샘플)을 선별하여 라벨러(연구자)에게 제시한다.
 - iv. 추가 라벨링된 데이터를 학습셋에 포함시켜 모델을 재학습한다. 이

과정을 3~5회 반복하여 분류 성능을 90% 이상으로 확보한다.

3.3 시공간적 불만 트렌드 분석 (Spatio-temporal Analysis)

분류된 민원 데이터를 시계열 및 지리 정보와 결합하여 사회 불만의 시공간적 패턴을 분석한다.

1. **시계열 분석 (Time-series Analysis):** 분류된 8개 주제별 민원 건수를 월별, 연도별로 집계한다. 단순 건수 변화와 함께, 전년 동기 대비 증감률 지표($\frac{t_n - t_{n-1}}{t_{n-1}}$)를 계산하여 계절성 요인(예: 여름철 '환경-해충' 민원)이나 특정 정책 이벤트 전후의 변화를 포착한다. 이는 시계열 라인 플롯으로 시각화한다.
2. **공간 분석 (Spatial Analysis):** 민원 발생 행정구역(region_code)을 기준으로 주제별 민원 발생 건수를 집계한다. 지역 간 공정한 비교를 위해, 통계청 인구 데이터를 결합하여 '인구 10만 명당 민원 발생 건수'로 정규화(normalization)한다. 이 정규화된 지표를 Geopandas와 Folium을 사용하여 지역별 히트맵(Heatmap)으로 시각화하며, 이를 통해 정책적 개입이 시급한 '불만 핫스팟' 지역을 식별한다.

3.4 주제 간 상관 네트워크 분석 (Topic Network Analysis)

사회 불만은 단일 주제로 발생하기보다 복수의 주제가 얹혀 발생하는 경우가 많다 (예: '주거' 민원에 '교통'과 '소음' 문제가 함께 언급). 이러한 문제의 구조적 연관성을 파악하기 위해 네트워크 분석을 도입한다.

1. **네트워크 정의:** 8개의 대주제를 노드(Node)로 정의한다.
2. **관계(Edge) 가중치 계산:** 단일 민원 문서(document) 내에서 2개 이상의 주제가 동시에 등장할 경우(co-occurrence), 해당 주제 노드 간의 엣지(Edge)에 +1의 가중치를 부여한다. 이 과정을 모든 민원에 대해 반복하여 주제 간 동시발생 가중치 행렬(Co-occurrence Matrix)을 생성한다.
3. **네트워크 분석:** NetworkX 라이브러리를 사용하여 가중치가 부여된 네트워크 그래프를 구축하고, 주요 네트워크 지표를 분석한다.
 - a. **연결 중심성 (Degree Centrality):** 가장 많은 주제와 연결된 '핵심 불만 주제'를 식별한다 (예: '주거'가 대부분의 다른 주제와 연결될 수 있음).

- b. **매개 중심성 (Betweenness Centrality):** 서로 다른 주제 군집을 연결하는 '매개자(bridge)' 역할을 하는 주제를 식별한다 (예: '행정' 문제가 '복지'와 '교통' 문제를 잇는 다리 역할을 할 수 있음).
- c. **커뮤니티 탐지 (Community Detection):** Louvain 알고리즘 등을 사용하여 강하게 상호작용하는 '문제 군집'을 도출한다 (예: {환경-소음, 주거-재개발, 교통-공사}가 하나의 군집으로 묶일 수 있음).

3.5 지표 설계 및 인터랙티브 대시보드 구축

모든 분석 결과를 통합하여, 정책 담당자가 직관적으로 트렌드를 파악하고 의사결정에 활용할 수 있는 인터랙티브 대시보드를 구축한다.

1. **핵심 지표 설계:** '주제별 민원 비중', '전년 대비 증가율', '지역별 정규화된 불만 지수', '주제 간 연결 강도' 등 핵심 지표(KPI)를 최종 정의한다.
2. **대시보드 구축:** Plotly (Dash) 또는 Streamlit을 사용하여 웹 기반 인터랙티브 대시보드를 개발한다.
3. **기대 기능:**
 - **시공간 필터링:** 사용자가 연도, 월, 특정 광역시를 선택하여 해당 조건의 데이터만 동적으로 조회할 수 있다.
 - **연동 시각화:** (a) 지도에서 특정 지역을 클릭하면, (b) 해당 지역의 시간별 민원 트렌드와 (c) 주제별 네트워크 구조가 연동되어 나타나는 3-Way 시각화를 구현한다.
 - **결과물:** 최종적으로 '사회 불만 트렌드맵'과 '문제 상관 네트워크 대시보드'를 완성하여 정책 우선순위 설정의 근거 자료로 제공한다.